



FSRCA: Fast Super Resolution with Residual Channel Attention

Teo Manuel Kaucher
tkaucher@udesa.edu.ar

Lucio Luque Materazzi
lluquematerazzi@udesa.edu.ar

MOTIVACIÓN Y DESARROLLO


En Super-Resolución de imágenes (SR) se busca aumentar la resolución de una imagen, efectivamente agrandando su tamaño en un factor de escala, generalmente entre 2, 3 y 4.

Este problema es sub-especificado, que quiere decir que hay distintas imágenes de alta resolución posibles para la de baja resolución.

Durante el trabajo se buscó primero replicar dos de los primeros modelos, SRCNN y FSRCNN, para luego implementar el propio (FSRCA), buscando balance entre velocidad y performance

DATASET

A lo largo del trabajo se utilizaron datasets conocidos para SR: T91 para entrenar, General100 para una etapa de *fine-tuning* y Set5 y Set14 para testear. Aunque los primeros dos tienen pocas imágenes, se aplican técnicas de *data augmentation* como rotación, inversión y escalado sobre el canal Y (luminancia) de YCbCr. Estas transformaciones generan miles de parches por cada imagen.



El Mono

Luego para cada parche HR (High Resolution) se genera su versión LR (low resolution). Los modelos SR buscan generar HR a partir de LR

MODELOS

SRCNN (Super-Resolution Convolutional Neural Network) fue el primer modelo de red convolucional para SR. Aplicando ReLU entre capas, su arquitectura básica es la siguiente:

- Interpolación bicúbica del input para escalar
- Extracción de características: Convolución (9x9)
- Mapeo no lineal: Convolución (3x3)
- Reconstrucción: Convolución (5x5)
- Parámetros totales: 24.416 (para factor 2)

FSRCNN (Fast SRCNN) fue desarrollado para mejorar a su antecesor en velocidad y precisión. Sigue una estructura similar con una mayor cantidad de capas, pero reemplaza la interpolación del principio con una convolución transpuesta al final. Esto reduce la velocidad de cómputo y permite reentrenar un modelo con un factor nuevo entrenando únicamente la última capa. Esta arquitectura resulta en 12.809 parámetros si se entrena para factor 2 desde 0 y en 4.537 si a partir de ella se finetunea para factor 4.

Proponemos FSRCA, basado en FSRCNN con conexiones residuales y técnicas de atención introducidas por otro modelo (RCAN). Esta arquitectura reemplaza el mapeo no lineal por un bloque RIR con 4 RCABs que contienen capas de atención, presentando 19.449 parámetros para los factores 2 y 4. A diferencia de los otros dos modelos que entrenamos con *MSE*, para este tipo de modelos se utilizó *L1*. La variante FSRCA PS sustituye la convolución transpuesta final por *PixelShuffle*, sin añadir parámetros, pero requiriendo una capa previa muy densa. Es por esto que se emplean solo dos bloques RCAB, sumando 27.764 y 82.208 parámetros para los factores 2 y 4.

RESULTADOS NUMÉRICOS

Tabla de comparación PSNR/SSIM de los métodos de interpolación

Dataset	Factor	NN	Bilineal	Bicúbico
Set5	2	29.53/0.9018	30.93/0.9108	32.63/0.9323
Set14	2	27.26/0.8494	27.93/0.8410	29.22/0.8761
Set5	4	24.94/0.7448	26.24/0.7808	27.31/0.8097
Set14	4	23.42/0.6585	24.19/0.6725	24.89/0.7047


Se verifica que el método de interpolación bicúbico es superior a vecinos más cercanos y bilineal.

Tabla de comparación PSNR/SSIM de interpolación bicúbica y CNNs


Dataset	Factor	Bicúbico	SRCNN	FSRCNN ft	FSRCA PS ft	FSRCA ft
Set5	2	32.63/0.9323	34.72/0.9496	34.54/0.9488	33.50/0.9413	34.64/ 0.9498
Set14	2	29.22/0.8761	30.70/0.8987	30.62/0.8988	29.94/0.8930	30.64/ 0.9000
Set5	4	27.31/0.8097	-	28.63/0.8467	-	28.81/0.8545
Set14	4	24.89/0.7047	-	25.87/0.7403	-	26.02/0.7464

- Es inesperado que SRCNN resulte mejor que FSRCNN. Probablemente se deba al entrenamiento reducido.
- SRCNN supera a FSRCA en PSNR, pero FSRCA tiene el mayor SSIM, que puede indicar una mejor calidad perceptual.
- PS resulta incluso peor que FSRCNN. Podría ser también debido al entrenamiento reducido o arquitectura limitada.

RESULTADOS VISUALES



En los resultados de factor 2 se observa que FSRCA PS genera una reconstrucción más ruidosa y menos fiel mientras que la interpolación bicúbica genera una suavización indeseada. Para los otros métodos no hay diferencias observables.



En los resultados de factor 4 se nota que la interpolación bicúbica también presenta los peores resultados. En cuanto a los otros modelos, en FSRCA se presenta mucho menos ruido que FSRCNN, quedando más similar a HR

TRABAJO FUTURO

Si tuviéramos más tiempo buscaríamos entrenar a los modelos con datos más variados y mayor data augmentation.

Sería interesante probar el entrenamiento con métricas más perceptuales, como el uso de VGG19.

Nos gustaría entrenar todos los modelos comparados para factor 4, en vez de solo a los de convergencia más rápida.